

PEDOMAN ANOTASI

INTER-ANNOTATOR AGREEMENT (IAA)

Validasi Reliabilitas Anotasi *Held-Out Naturalistic Test Set*

Penelitian Tugas Akhir

Pengembangan Sistem Network Data Leakage Prevention dengan Metode Hibrida Rule-Based dan Machine Learning pada Data Kependudukan

Peneliti:

Arga Ariyuda Avian

NPM: 2221101774

Program Studi Rekayasa Keamanan Siber

Politeknik Siber dan Sandi Negara

Dosen Pembimbing:

Tiyas Yulita, M.Si.

A. Landasan Panduan Anotasi

Dokumen ini menyusun pedoman baku pelaksanaan anotasi manual pada *held-out naturalistic test set* penelitian ini, guna memperoleh reliabilitas anotasi (*ground truth*) yang dapat dipertanggungjawabkan secara akademik dan menjadi dasar validitas evaluasi model deteksi PII.

Penyusunan pedoman anotasi didasarkan pada tiga landasan utama. Landasan pertama adalah standar skema pelabelan sekuensial CoNLL-2003 yang diperkenalkan oleh Tjong Kim Sang dan De Meulder (2003), yang hingga saat ini masih digunakan secara luas sebagai acuan dalam tugas *Named Entity Recognition* (NER). Landasan kedua mengacu pada praktik pengukuran *Inter-Annotator Agreement* (IAA) yang direkomendasikan dalam berbagai penelitian (Hripcsak & Rothschild, 2005; Artstein & Poesio, 2008), dengan mempertimbangkan keterbatasan penggunaan Cohen's Kappa pada distribusi label yang tidak seimbang sebagaimana dijelaskan oleh Feinstein dan Cicchetti (1990) serta Gwet (2008). Landasan ketiga berasal dari regulasi nasional yang mengatur perlindungan data pribadi dan tata kelola data kependudukan, yaitu Undang-Undang Nomor 27 Tahun 2022 tentang Perlindungan Data Pribadi, Peraturan Pemerintah Nomor 40 Tahun 2019, dan Peraturan Menteri Dalam Negeri Nomor 137 Tahun 2017.

B. Identitas Anotator

B.1 Anotator A (Peneliti)

Atribut	Rincian
Nama Lengkap	Arga Ariyuda Avian
NIM	2221101774
Institusi	Politeknik Siber dan Sandi Negara
Peran	Peneliti utama sekaligus Anotator A
Bidang Keahlian	Rekayasa keamanan siber, khususnya: • <i>Network-based Data Leakage Prevention</i> (NDLP) • <i>Named Entity Recognition</i> (NER) untuk PII kependudukan Indonesia • Model hibrida <i>rule-based</i> + <i>Conditional Random Fields</i> (CRF)

B.2 Anotator B (Independen)

Atribut	Rincian
Nama Lengkap	Muhammad Abdul Aziz Ghazali, S.T.
Latar Belakang Pendidikan	Sarjana Teknik, Program Studi Teknik Informatika
Bidang Keahlian	<i>Machine Learning</i> (ML) & <i>Natural Language Processing</i> (NLP)
Hubungan dengan Peneliti	Rekan profesional, bertindak sebagai anotator independen tanpa keterlibatan pada tahap desain penelitian, pembangkitan dataset, maupun pelatihan model
Justifikasi Pemilihan	Memiliki latar belakang formal Teknik Informatika dan familiar dengan skema BIO tagging untuk tugas NER, sehingga kompeten untuk

Atribut	Rincian
	melakukan anotasi entitas PII pada teks berbahasa Indonesia secara mandiri.

C. Ruang Lingkup dan Tujuan Anotasi

Anotasi dilakukan terhadap 200 sampel yang dipilih secara *stratified random sampling* dari *held-out naturalistic test set* dengan SEED=42, merepresentasikan 20% dari total 1.000 sampel *held-out*. Seluruh sampel mencakup tujuh format payload representatif dari penggunaan PII di dunia nyata.

C.1 Lima Entitas PII yang Dianotasi

Label	Nama Lengkap	Deskripsi
NIK	Nomor Induk Kependudukan	Nomor identitas penduduk Indonesia 16 digit sesuai Permendagri No. 137/2017. Format: PP-KK-CC-DD-MM-YY-NNNN. Laki-laki: DD = tanggal lahir asli (01–31). Perempuan: DD = tanggal lahir + 40 (41–71).
PHONE	Nomor Telepon Indonesia	Nomor telepon dengan prefix +62 atau 0, total 10-13 digit, diawali dengan kode operator (011x, 012x, 013x, 014x, 015x, 08xx).
NAMA	Nama Lengkap Orang	Nama dapat terdiri dari satu hingga beberapa kata. Gelar akademik (S.Kom., M.Si., dr., dll.) dan gelar kebangsawanan yang berdiri sendiri tidak termasuk dalam anotasi.
JABATAN	Jabatan Formal	Jabatan resmi dalam struktur organisasi pemerintahan (Camat, Lurah, Kepala Dinas, Gubernur, dll.) maupun swasta/akademik (Direktur, Manajer, CEO, Dosen, Rektor, dll.). Nama institusi (Dinas Pendidikan, ITB, PoltekSSN) BUKAN JABATAN lihat Bagian E.4 dan Bagian F.
LOKASI	Wilayah Geografis Indonesia	Nama wilayah geografis Indonesia: provinsi, kabupaten, kota, kecamatan, kelurahan/desa, nama jalan. Kata

Label	Nama Lengkap	Deskripsi
		"Kota" yang berdiri sendiri tanpa nama wilayah TIDAK dianotasi sebagai LOKASI.

C.2 Tujuh Format Payload Dataset

No.	Format Payload	Karakteristik
1	<i>Email Signature</i>	Tanda tangan email formal berisi nama, jabatan, nomor telepon, dan lokasi instansi
2	<i>Database Export</i>	Data tabular hasil ekspor basis data, sering berisi NIK, nama, dan nomor telepon dalam format terstruktur
3	<i>Customer Service Log</i>	Log percakapan layanan pelanggan, PII muncul dalam konteks naratif dan tidak terstruktur
4	<i>Government Letter</i>	Surat resmi pemerintahan berisi identitas pejabat, jabatan, dan wilayah administratif
5	<i>JSON Streaming Log</i>	Log sistem dalam format JSON; PII tertanam sebagai nilai field
6	<i>Tabular CSV/TSV</i>	Data tabular dipisah koma atau tab; setiap baris merepresentasikan satu record
7	<i>Multi-PII Context</i>	Teks bebas yang mengandung kombinasi beberapa entitas PII sekaligus

D. Skema Pelabelan BIO Tagging

Anotasi menggunakan skema BIO (*Beginning-Inside-Outside*) yang merupakan standar dalam tugas *Named Entity Recognition* (NER) sesuai CoNLL-2003 (Tjong Kim Sang & De Meulder, 2003).

Prefiks	Kepanjangan	Makna	Contoh Token
B-	Beginning	Token pertama (atau satu-satunya) dari sebuah entitas	B-NAMA pada token "Budi"
I-	Inside	Token lanjutan dari entitas yang sama (setelah B-)	I-NAMA pada token "Santoso" (setelah "Budi")
O	Outside	Token yang bukan bagian dari entitas PII manapun	O pada token "adalah", "di", tanda baca

Daftar Lengkap Label (11 Label):

Label	Entitas	Deskripsi
B-NIK	NIK	Token pertama atau token tunggal NIK (16 digit)
B-PHONE	PHONE	Token pertama atau token tunggal nomor telepon
I-PHONE	PHONE	Token lanjutan nomor telepon bila dipisah spasi/hubung
B-NAMA	NAMA	Token pertama dari nama orang
I-NAMA	NAMA	Token lanjutan dari nama orang (kata kedua, ketiga, dst.)
B-JABATAN	JABATAN	Token pertama dari jabatan formal
I-JABATAN	JABATAN	Token lanjutan dari jabatan formal
B-LOKASI	LOKASI	Token pertama dari wilayah geografis
I-LOKASI	LOKASI	Token lanjutan dari wilayah geografis

Label	Entitas	Deskripsi
O	(bukan entitas)	Token di luar semua entitas PII, termasuk nama institusi, tanda baca, konjungsi, preposisi

E. Aturan Anotasi Per Entitas

E.1 Anotasi NIK

1. NIK terdiri dari 16 digit angka, mengikuti format PP-KK-CC-DD-MM-YY-NNNN sesuai Permendagri No. 137 Tahun 2017.
2. Meskipun format ideal NIK dipisah dengan tanda hubung, dalam dataset ini NIK ditulis berurutan tanpa pemisah (contoh: 3271014507890001) sebagai satu token tunggal, sehingga dianotasi B-NIK.
3. Bila NIK dipisah spasi karena kesalahan format sumber data, seluruh fragmen dianotasi sebagai satu entitas dengan skema B-NIK + I-NIK.
4. Angka 16 digit yang jelas BUKAN NIK (misal Order ID, Invoice Number, Tracking Number) diberi label O, lihat kasus 1 pada Bagian F.

Contoh:

"NIK saya 3271014507890001, tolong dicatat"

- NIK → O
- saya → O
- 3271014507890001 → B-NIK
- , → O
- tolong → O
- dicatat → O

E.2 Anotasi PHONE

5. Nomor telepon Indonesia dengan prefix +62 atau 0, panjang 10-13 digit, dan kode operator resmi Kominfo (contoh: 0811-0813 Telkomsel, 0821-0823 Telkomsel, 0851-0858 Indosat).
6. Nomor yang ditulis utuh tanpa pemisah dianotasi sebagai B-PHONE tunggal (contoh: 081234567890 → B-PHONE).
7. Nomor yang dipisah spasi atau tanda hubung dianotasi sebagai B-PHONE + I-PHONE (contoh: 0812 3456 7890 → B-PHONE I-PHONE I-PHONE).
8. Nomor telepon internasional non-Indonesia (contoh: +1-, +44-, +65-) diberi label O karena di luar cakupan PII kependudukan Indonesia.

E.3 Anotasi NAMA

9. Nama lengkap orang, dapat terdiri dari satu hingga beberapa kata. Token pertama diberi label B-NAMA, token lanjutan I-NAMA.
10. Gelar akademik yang berdiri sendiri (S.Kom., M.Si., dr., Ir., dan sejenisnya) TIDAK dianotasi sebagai bagian NAMA, beri label O.
11. Gelar kebangsawanan yang berdiri sendiri (H., Hj., R., R.A., dan sejenisnya) TIDAK dianotasi sebagai bagian NAMA, beri label O.
12. Bila gelar menyatu tanpa spasi dengan nama (contoh: "H.Ahmad"), pisahkan hanya bagian nama yang dianotasi. Lihat kasus 6 pada Bagian F.
13. Inisial (contoh: "A. Sudrajat") dianotasi B-NAMA + I-NAMA apabila konteks jelas merujuk pada nama orang.

Contoh:

"Ditandatangani oleh dr. Budi Santoso, M.Kes."

- Ditandatangani → O
- oleh → O
- dr. → O
- Budi → B-NAMA
- Santoso → I-NAMA
- , → O
- M.Kes. → O

E.4 Anotasi JABATAN

Prinsip dasar JABATAN adalah posisi/jabatan formal yang dapat dijabat seseorang, bukan nama organisasi/institusi itu sendiri. Kesalahan paling umum pada tugas ini adalah menandai nama instansi ("Dinas Pendidikan", "Politeknik Siber dan Sandi Negara", "ITB") sebagai JABATAN, hal ini keliru dan harus dilabeli O.

14. Jabatan pemerintahan (Camat, Lurah, Kepala Desa, Kepala Dinas, Kepala Bidang, Gubernur, Bupati, Walikota, Sekretaris Daerah, dan sejenisnya).
15. Jabatan swasta dan akademik (Direktur Utama, Direktur, Manajer, CEO, CFO, CTO, Dosen, Profesor, Rektor, Dekan, Kepala Program Studi, dan sejenisnya).
16. Jabatan multi-kata dianotasi penuh sampai batas akhir jabatan tersebut. Contoh: "Kepala Dinas Pendidikan", jika "Dinas Pendidikan" berperan sebagai kualifikasi

jabatan (menjelaskan Kepala apa), maka "Kepala" (B-JABATAN), "Dinas" (I-JABATAN), "Pendidikan" (I-JABATAN).

17. Kata jabatan generik tanpa konteks yang jelas (misal kata "Kepala" yang merujuk pada bagian tubuh atau kepala dokumen) diberi label O.

Contoh penerapan aturan disambiguasi JABATAN vs Institusi:

Kalimat	Anotasi Benar	Alasan
"selaku Kepala Dinas Kependudukan"	Kepala (B-JABATAN), Dinas (I-JABATAN), Kependudukan (I-JABATAN)	"Dinas Kependudukan" adalah kualifikasi dari Kepala. Frasa utuh adalah jabatan orang tersebut.
"bekerja di Dinas Kependudukan"	bekerja (O), di (O), Dinas (O), Kependudukan (O)	"Dinas Kependudukan" berdiri sendiri sebagai nama institusi tempat kerja, bukan jabatan.
"Dinas Pendidikan Kota Bogor" (sebagai nama instansi surat)	Dinas (O), Pendidikan (O), Kota (B-LOKASI), Bogor (I-LOKASI)	Nama instansi lepas → O. "Kota Bogor" tetap LOKASI.
"Direktur PT Semen Indonesia"	Direktur (B-JABATAN); PT (O), Semen (O), Indonesia (O)	Hanya "Direktur" yang jabatan. "PT Semen Indonesia" adalah nama perusahaan → O.
"Ketua Program Studi Teknik Informatika ITB"	Ketua (B-JABATAN), Program (I-JABATAN), Studi (I-JABATAN), Teknik (I-JABATAN), Informatika (I-JABATAN); ITB (O)	"Ketua Program Studi Teknik Informatika" adalah jabatan utuh. "ITB" adalah nama institusi → O.

E.5 Anotasi LOKASI

18. Cakupan: nama provinsi, kabupaten, kota, kecamatan, kelurahan/desa, nama jalan, nama gedung (sebagai penanda lokasi).
19. Kata "Kota" yang tidak diikuti nama wilayah (contoh: "di kota ini", "pemerintah kota") diberi label O. Namun "Kota Bogor", "Kota Bandung" dianotasi sebagai B-LOKASI + I-LOKASI.
20. Singkatan wilayah yang diakui resmi (DKI, DIY, NTB, NTT, dst.) dianotasi sebagai B-LOKASI.
21. Nama jalan yang menyertakan nomor dianotasi sebagai satu entitas: "Jalan" (B-LOKASI) "Merdeka" (I-LOKASI) "No." (I-LOKASI) "10" (I-LOKASI).
22. Kata "Indonesia" yang berdiri sendiri sebagai nama negara TIDAK dianotasi sebagai LOKASI dalam konteks penelitian ini, karena penelitian berfokus pada wilayah administratif di dalam Indonesia.

Contoh:

"berdomisili di Kecamatan Bogor Utara, Kota Bogor"

- berdomisili → O
- di → O
- Kecamatan → B-LOKASI
- Bogor → I-LOKASI
- Utara → I-LOKASI
- , → O
- Kota → B-LOKASI
- Bogor → I-LOKASI

F. Penanganan Kasus Khusus dan Ambigu

Tabel berikut mendefinisikan aturan untuk sepuluh edge case yang berpotensi ambigu dalam proses anotasi. Anotator wajib merujuk tabel ini apabila menemukan kasus serupa selama proses anotasi.

No.	Kasus	Aturan Penanganan
1	Angka 16 digit sebagai order_id / invoice / tracking	Periksa konteks nama field. Jika bukan NIK kependudukan (contoh: order_id, invoice_no, tracking_no) → label O.
2	Nama yang identik dengan kata jabatan	Contoh: orang bernama "Camat". Tentukan berdasarkan konteks kalimat apakah merujuk pada identitas orang atau jabatan.
3	Singkatan nama (inisial)	Anotasi B-NAMA + I-NAMA apabila konteks jelas menunjukkan nama orang (contoh: "atas nama A. Sudrajat").
4	Nomor telepon dengan pemisah spasi/tanda hubung	Anotasi seluruh token sebagai satu entitas PHONE (B-PHONE untuk token pertama, I-PHONE untuk berikutnya).
5	LOKASI yang juga bagian nama instansi	Contoh: "Dinas Pendidikan Kota Bogor". "Dinas Pendidikan" → O (nama instansi). "Kota Bogor" → LOKASI. Anotasi terpisah.
6	Nama dengan gelar yang menyatu (tanpa spasi)	Contoh: "H.Ahmad Yani". Anotasi hanya bagian nama inti: "Ahmad" (B-NAMA), "Yani" (I-NAMA). "H." → O.
7	Nama institusi/organisasi bukan nama orang	Contoh: "Politeknik Siber dan Sandi Negara", "Institut Teknologi Bandung", "PT Bank Mandiri" adalah nama institusi → label O (tidak termasuk entitas PII yang dianotasi).
8	Entitas PII yang terpotong / tidak lengkap	NIK atau PHONE yang tidak lengkap (kurang digit) karena redaksi dokumen tetap diberi label sesuai konteks yang

No.	Kasus	Aturan Penanganan
		menunjukkan jenis entitas, dengan catatan pada kolom komentar.
9	Jabatan diikuti nama institusi tanpa preposisi	Contoh: "Direktur Bank Mandiri". "Direktur" adalah JABATAN inti; "Bank Mandiri" adalah nama institusi tempat menjabat, dilabeli O, karena bukan bagian dari titel jabatan formal seseorang.
10	Ambiguitas gelar kehormatan/keagamaan	Gelar seperti "Pak", "Ibu", "Bapak", "Ustadz", "KH" TIDAK dianotasi sebagai bagian NAMA. Beri label O. Contoh: "Pak Budi" → "Pak" (O), "Budi" (B-NAMA).

G. Prosedur Pelaksanaan Anotasi

Anotasi dilakukan secara terpisah dan independen oleh Anotator A dan Anotator B menggunakan data sampel yang identik (SEED=42). Prosedur dilakukan dalam dua tahap: tahap kalibrasi (Bagian G.1) dan tahap anotasi utama (Bagian G.2).

G.1 Tahap Kalibrasi (Wajib, Sebelum Anotasi Utama)

Bertujuan menyamakan persepsi kedua anotator terhadap pedoman ini sebelum mengerjakan 200 sampel resmi, sehingga potensi kesalahpahaman aturan dapat dideteksi dan diperbaiki di awal, bukan setelah 200 sampel selesai dan ternyata κ rendah karena beda interpretasi.

1. Anotator A menyiapkan 10 sampel kalibrasi yang mewakili variasi tujuh format payload dan kelima entitas. Sampel kalibrasi ini tidak termasuk 200 sampel utama.
2. Kedua anotator melabel 10 sampel tersebut secara independen di HumanSignal.
3. Setelah selesai, kedua anotator saling berdiskusi secara terbuka membandingkan hasilnya. Diskusi terfokus pada sumber ketidaksepakatan dan interpretasi aturan.
4. Bila ditemukan aturan pedoman yang ambigu atau belum tercakup, Anotator A merevisi dokumen pedoman ini dan menerbitkan versi baru.
5. Setelah pedoman final disepakati kedua pihak, tahap kalibrasi ditutup dan tahap anotasi utama (G.2) dapat dimulai. Tidak ada diskusi antar anotator hingga seluruh 200 sampel selesai dianotasi.

G.2 Tahap Anotasi Utama

23. Anotator A menerbitkan proyek HumanSignal berisi 200 sampel identik untuk kedua anotator. Konfigurasi proyek WAJIB: Overlap of Annotations = 100%, minimum annotators per task = 2.
24. Anotator B menerima undangan akses ke proyek dengan role "Annotator" (BUKAN role Manager/Reviewer/Admin) sehingga tidak dapat melihat hasil anotasi Anotator A selama proses berlangsung (*blind annotation*).
25. Kedua anotator membaca ulang Bagian E dan F pedoman ini secara menyeluruh sebelum memulai anotasi.
26. Anotasi dilakukan secara mandiri. Dilarang mendiskusikan atau membandingkan hasil anotasi antara Anotator A, Anotator B, atau pihak lain selama seluruh 200 sampel belum selesai dianotasi kedua pihak.

27. Kasus ambigu yang ditemui dicatat pada kolom komentar HumanSignal per task, dilengkapi alasan keputusan yang diambil. Catatan ini digunakan untuk analisis kualitatif pelengkap nilai IAA.
28. Setelah kedua anotator menyelesaikan seluruh 200 sampel, Anotator A mengekspor hasil kedua anotator dari HumanSignal (format JSON-MIN atau JSON default) dan menjalankan skrip perhitungan IAA (Bagian I.3).

H. Spesifikasi Tool Anotasi

H.1 Tool yang Digunakan: HumanSignal (Label Studio)

Tool anotasi resmi yang digunakan dalam penelitian ini adalah HumanSignal (URL: <https://labelstud.io> yang sebelumnya dikenal sebagai Label Studio). Pemilihan tool ini didasarkan pada:

- Dukungan native untuk skema BIO tagging pada tugas NER dengan interface visual span-selection
- Dukungan *multi-annotator* dengan konfigurasi *Overlap of Annotations* yang dapat disesuaikan
- Dukungan *role-based access control* (RBAC) yang memungkinkan *blind annotation* dengan pemberian role Annotator kepada Anotator B
- Format ekspor JSON dan CoNLL yang kompatibel dengan pipeline evaluasi sequeval (Python)
- Fitur komentar per task untuk mendokumentasikan kasus ambigu selama anotasi

H.2 Prinsip Metodologis Konfigurasi Tool

No.	Prinsip	Konfigurasi HumanSignal
1	<i>Blind Annotation</i>	Anotator B diberi role "Annotator" (bukan Reviewer/Manager), sehingga tidak dapat melihat anotasi Anotator A pada task yang sama
2	<i>Overlap 100%</i>	Settings → Annotation → "Overlap of Annotations" = 100%; "Minimum annotators per task" = 2. Setiap dari 200 task wajib dianotasi oleh kedua anotator.
3	<i>Token-level Granularity</i>	Label configuration menggunakan tag <Labels> pada tag <Text> dengan lima entitas: NIK, PHONE, NAMA, JABATAN, LOKASI
4	<i>Reproducible Sampling</i>	Dataset diambil dari held-out set dengan SEED=42; kedua anotator mengerjakan file JSON impor yang identik

No.	Prinsip	Konfigurasi HumanSignal
5	<i>Audit Trail</i>	HumanSignal mencatat timestamp submit setiap annotation; export JSON menyertakan <code>created_at</code> dan <code>updated_at</code> per annotation
6	<i>Komentar Inline</i>	Fitur "Add annotation comment" pada UI HumanSignal digunakan untuk mendokumentasikan alasan pada kasus ambigu
7	<i>Progress Tracking</i>	Data Manager menampilkan kolom "Task State" (Annotating/Submitted) dan progress agregat pada footer

H.3 Label Configuration HumanSignal

Label configuration:

```
<View>
  <Labels name="label" toName="text">
    <Label value="NIK" background="#FF6B6B"/>
    <Label value="PHONE" background="#4ECDC4"/>
    <Label value="NAMA" background="#FFE66D"/>
    <Label value="JABATAN" background="#95E1D3"/>
    <Label value="LOKASI" background="#C9B1FF"/>
  </Labels>
  <Text name="text" value="$text"/>
</View>
```

H.4 Konfigurasi Wajib pada Project Settings

Setelah membuat proyek, konfigurasi berikut wajib diperiksa pada menu *Settings* → *Annotation*:

- Overlap of Annotations: 100%
- Minimum annotators per task: 2
- Annotation instruction: link ke dokumen pedoman ini
- *Reveal preannotations interactively*: OFF (tidak diperlukan; tidak ada model predictions)

H.5 Prosedur Ekspor Hasil

Setelah kedua anotator menyelesaikan seluruh 200 sampel, Anotator A melakukan ekspor melalui:

1. Buka Data Manager proyek.
2. Klik tombol Export.
3. Pilih format JSON.
4. Simpan file sebagai anotasi_raw_export.json.
5. Jalankan skrip `31_compute_inter_kappa.py` untuk menghitung Span-F1, Cohen's Kappa, dan Gwet's AC1 secara otomatis.

Angka "*Agreement*" yang muncul pada UI HumanSignal (kolom Agreement pada Data Manager) hanya tersedia pada edisi Starter Cloud/Enterprise, dan mekanisme perhitungannya berbasis *consensus score* internal, bukan nilai Cohen's Kappa, Span-F1, atau Gwet's AC1 yang standar akademik. Oleh karena itu, penelitian ini tidak menggunakan angka Agreement bawaan HumanSignal, melainkan menghitung tiga metrik IAA komplementer secara mandiri dari hasil ekspor JSON menggunakan skrip Python dapat direproduksi.

I. Metrik Inter-Annotator Agreement dan Target

I.1 Pemilihan Metrik: Tiga Metrik Komplementer

Berbeda dengan tugas klasifikasi biasa, tugas NER memiliki dua karakteristik yang membuat Cohen's Kappa tunggal tidak memadai sebagai metrik IAA:

1. Ketidakjelasan definisi kasus negatif. NER adalah tugas sequence tagging, jumlah "kasus negatif" bergantung pada tokenizer yang digunakan (Hripcsak & Rothschild, 2005). Bila dihitung pada semua token termasuk label O, label O yang mendominasi (74% pada dataset ini per Tabel 4.9) akan membanjiri statistik dan menghasilkan κ yang menyesatkan.
2. Kappa Paradox pada Distribusi Timpang. Feinstein dan Cicchetti (1990) menunjukkan bahwa κ dapat jatuh drastis meskipun observed agreement (P_o) tinggi, apabila distribusi marginal timpang. Gwet (2008) menawarkan AC1 sebagai koefisien *paradox-resistant* yang lebih stabil pada distribusi timpang.

Mengikuti praktik penelitian NER terkini (mis. PrionNER 2026, Chinese-SkillSpan 2026, CrudeOilNews 2022), penelitian ini melaporkan tiga metrik komplementer:

Metrik	Level	Sumber	Fungsi
Span-level Pairwise F1 (<i>strict + relaxed</i>)	Entitas	Tjong Kim Sang & De Meulder (2003); Hripcsak & Rothschild (2005)	Metrik utama, mengukur kesepakatan pada batas dan tipe entitas, standar de-facto untuk NER
Cohen's Kappa (tanpa "O")	Token	Cohen (1960); Artstein & Poesio (2008)	Metrik pelengkap, dilaporkan karena umum dikenal, dihitung hanya pada token bertag entitas (bukan O) agar tidak kena kappa paradox
Gwet's AC1	Token	Gwet (2008)	Metrik paradox-resistant, jaring pengaman bila κ turun akibat distribusi timpang; lebih

Metrik	Level	Sumber	Fungsi
			stabil pada prevalensi kelas ekstrem

I.2 Formula Metrik

(a) Span-level Pairwise F1 (Strict)

Sebuah entitas dianggap disepakati kedua anotator apabila (1) tipe entitas sama dan (2) batas awal-akhir span identik. Perhitungan menggunakan library `segeval` Python yang mengimplementasikan aturan CoNLL-2003.

$$F1_strict = 2 \times Precision \times Recall / (Precision + Recall)$$

dengan Anotator A diperlakukan sebagai *gold* dan Anotator B sebagai *predicted* (F1 pairwise bersifat simetris).

(b) Span-level Pairwise F1 (Relaxed)

Sama dengan strict, tetapi kesepakatan diberikan apabila kedua span memiliki overlap ≥ 1 token dengan tipe entitas yang sama (mengukur kesepakatan tipe entitas terpisah dari kesepakatan boundary). Selisih strict vs relaxed mengungkap kontribusi boundary error terhadap total ketidaksepakatan.

(c) Cohen's Kappa (Token-level, tanpa "O")

$$\kappa = (P_o - P_e) / (1 - P_e)$$

dihitung hanya pada subset token yang di-tag sebagai entitas (bukan O) oleh setidaknya satu anotator, mengikuti pola *CrudeOilNews* (2022) dan *Tweetbank* (2022) untuk menghindari bias dari kelas mayoritas O.

(d) Gwet's AC1

$$AC1 = (P_a - P_{e_gwet}) / (1 - P_{e_gwet})$$

dengan $P_{e_gwet} = 2 \times \pi \times (1 - \pi)$ (untuk klasifikasi biner; formula multiclass menggunakan generalisasi Gwet 2008), di mana π adalah proporsi kesepakatan positif marginal. Perbedaan utama dari κ terletak pada perhitungan expected agreement yang tidak bergantung pada prevalensi kelas.

I.3 Perhitungan Otomatis dengan Skrip

Ketiga metrik dihitung otomatis dari file ekspor JSON HumanSignal menggunakan skrip `scripts/31_compute_inter_kappa.py`. Skrip ini menggunakan library:

- `segeval` (Nakayama, 2018) untuk Span-level Pairwise F1
- `scikit-learn cohen_kappa_score` untuk Cohen's Kappa token-level
- `irrCAC` atau kustom implementasi Gwet AC1

I.4 Interpretasi Nilai (Landis & Koch, 1977)

Kedua metrik (Cohen's Kappa dan Gwet's AC1) menggunakan skala interpretasi Landis & Koch. Span-F1 tidak memiliki interpretasi Landis-Koch resmi tetapi dapat ditafsirkan menggunakan skala yang sama secara konvensional.

Rentang Nilai	Kategori	Keterangan
< 0,00	Poor	Kesepakatan di bawah peluang acak
0,00 – 0,20	Slight	Kesepakatan sangat lemah
0,21 – 0,40	Fair	Kesepakatan lemah
0,41 – 0,60	Moderate	Kesepakatan cukup
0,61 – 0,80	Substantial	Kesepakatan baik
0,81 – 1,00	Almost Perfect	Target penelitian

I.5 Target Penelitian

Target primer: Span-level Pairwise F1 (strict) $\geq 0,75$ DAN Gwet's AC1 $\geq 0,80$.

Justifikasi pemilihan target:

- Span-F1 strict $\geq 0,75$ mencerminkan tingkat kesepakatan wajar untuk NER pada teks naturalistik dengan *boundary ambiguity*, sejalan dengan penelitian NER terkini (Chinese-SkillSpan 2026 melaporkan 0,532; PrionNER 2026 melaporkan 0,818). Nilai 0,75 dipilih sebagai kompromi antara realisme empiris dan integritas metodologis.
- Gwet's AC1 $\geq 0,80$ digunakan sebagai metrik *paradox-resistant* utama pada level token karena distribusi label O yang mendominasi (74%) berpotensi memicu kappa paradox pada Cohen's Kappa konvensional.

- Cohen's Kappa tanpa "O" dilaporkan sebagai referensi silang; nilainya diharapkan berada pada rentang Substantial-Almost Perfect (0,61-1,00) dan digunakan untuk memvalidasi konsistensi dengan Gwet's AC1.

I.6 Prosedur Adjudikasi bila Target Tidak Tercapai

Apabila salah satu atau kedua metrik primer di bawah target, dilakukan tahap adjudikasi formal untuk menghasilkan *ground truth* final. Prosedur ini wajib dilaksanakan agar dataset *held-out* tetap dapat digunakan sebagai referensi evaluasi model:

1. Anotator A mengidentifikasi seluruh token dan/atau span di mana Anotator A dan B berbeda pendapat menggunakan output skrip perhitungan.
2. Kasus-kasus tidak sepakat dikategorikan ke dalam empat kelompok: (a) boundary disagreement (kedua anotator setuju tipe entitas, beda batas span), (b) type disagreement (batas sama, tipe entitas beda), (c) missing detection (satu anotator menandai, satu tidak), (d) genuine ambiguity (kasus yang memang tidak tercakup pedoman).
3. Anotator A dan B melakukan diskusi terarah untuk setiap kasus tidak sepakat, dengan merujuk pada Bagian E dan F pedoman ini. Diskusi dicatat dalam log adjudikasi.
4. Bila diskusi mencapai kesepakatan, label yang disepakati menjadi *gold standard* final untuk token/span tersebut.
5. Bila diskusi tidak mencapai kesepakatan (kasus benar-benar ambigu di luar pedoman), Dosen Pembimbing berperan sebagai adjudicator ketiga untuk memutuskan label final. Keputusan ini dicatat sebagai preseden untuk kasus serupa.
6. Setelah adjudikasi selesai, hasil final digunakan sebagai *ground truth held-out set*. Nilai IAA pra-adjudikasi tetap dilaporkan di laporan penelitian sebagai bukti proses reliabilitas, disertai catatan proporsi kasus yang diadjudikasi.

K. Daftar Referensi

- Artstein, R., & Poesio, M. (2008). *Inter-coder agreement for computational linguistics. Computational Linguistics*, 34(4), 555–596. <https://doi.org/10.1162/coli.07-034-R2>
- Cohen, J. (1960). *A coefficient of agreement for nominal scales. Educational and Psychological Measurement*, 20(1), 37–46. <https://doi.org/10.1177/001316446002000104>
- Feinstein, A. R., & Cicchetti, D. V. (1990). *High agreement but low kappa: I. The problems of two paradoxes. Journal of Clinical Epidemiology*, 43(6), 543–549. [https://doi.org/10.1016/0895-4356\(90\)90158-L](https://doi.org/10.1016/0895-4356(90)90158-L)
- Gwet, K. L. (2008). *Computing inter-rater reliability and its variance in the presence of high agreement. British Journal of Mathematical and Statistical Psychology*, 61(1), 29–48. <https://doi.org/10.1348/000711006X126600>
- Hripcsak, G., & Rothschild, A. S. (2005). *Agreement, the F-measure, and reliability in information retrieval. Journal of the American Medical Informatics Association*, 12(3), 296–298. <https://doi.org/10.1197/jamia.M1733>
- Lafferty, J., McCallum, A., & Pereira, F. (2001). *Conditional random fields: Probabilistic models for segmenting and labeling sequence data. Proceedings of the 18th International Conference on Machine Learning (ICML 2001)*, 282–289.
- Landis, J. R., & Koch, G. G. (1977). *The measurement of observer agreement for categorical data. Biometrics*, 33(1), 159–174. <https://doi.org/10.2307/2529310>
- Nakayama, H. (2018). *segeval: A Python framework for sequence labeling evaluation*. <https://github.com/chakki-works/segeval>
- Peraturan Menteri Dalam Negeri Republik Indonesia Nomor 137 Tahun 2017 *tentang Kode dan Data Wilayah Administrasi Pemerintahan. Berita Negara Republik Indonesia Tahun 2017 Nomor 1955*.
- Peraturan Pemerintah Republik Indonesia Nomor 40 Tahun 2019 *tentang Pelaksanaan Undang-Undang Nomor 23 Tahun 2006 tentang Administrasi Kependudukan sebagaimana telah diubah dengan Undang-Undang Nomor 24 Tahun 2013. Lembaran Negara Republik Indonesia Tahun 2019 Nomor 102*.
- Tjong Kim Sang, E. F., & De Meulder, F. (2003). *Introduction to the CoNLL-2003 shared task: Language-independent named entity recognition. Proceedings of the 7th Conference on Natural Language Learning at HLT-NAACL 2003 (CoNLL-2003)*, 142–147. <https://doi.org/10.3115/1119176.1119195>

Undang-Undang Republik Indonesia Nomor 27 Tahun 2022 *tentang Perlindungan Data Pribadi. Lembaran Negara Republik Indonesia Tahun 2022 Nomor 196, Tambahan Lembaran Negara Nomor 6820.*